

SRS – Smart CRM Mekong Mobile · L7: Chất lượng dữ liệu khách hàng

Mục	Nội dung
Sinh viên	Dương Diễm My – MSSV 2374802010318
Track	DA (Data Analytics)
Học phần	Chuyên đề Tốt nghiệp 1 – Trường ĐH Văn Lang
Luồng nghiệp vụ	L7 – Chất lượng dữ liệu khách hàng
Tài liệu liên quan	docs/usecase_L7.drawio, docs/data-requirement-spec.md

Phạm vi một câu: Nạp tệp khách hàng thô, chuẩn hóa số điện thoại và họ tên, phát hiện cặp hồ sơ nghi trùng bằng so khớp mờ để nhân viên Marketing xác nhận gộp hoặc giữ riêng, rồi đo và báo cáo chỉ số mức độ sạch dữ liệu theo từng đợt nạp.

1. Giới thiệu

1.1. Mục đích

Tài liệu đặc tả yêu cầu cho luồng L7 của hệ thống Smart CRM Mekong Mobile: phát hiện hồ sơ trùng, thiếu, sai định dạng trong dữ liệu khách hàng; chuẩn hóa dữ liệu; đo và báo cáo mức độ sạch theo thời gian. Luồng giải quyết vấn đề V1 của case study (khách hàng nằm rải rác ở Excel, Zalo, sổ tay; ước tính 18–22% hồ sơ trùng).

1.2. Phạm vi

Làm

- Nạp dữ liệu khách hàng thô (CSV/Excel) vào bảng tạm `stg_customer`.
- Chuẩn hóa số điện thoại (QT-02) và họ tên.
- Phát hiện cặp nghi trùng bằng so khớp mờ, tính điểm tương đồng.
- Cho nhân viên Marketing xem, xác nhận gộp hoặc giữ riêng; cập nhật `customer_clean`.
- Cấu hình bộ quy tắc chất lượng dữ liệu (`dq_rule`), tính và lưu chỉ số mức độ sạch (`dq_result`) theo đợt nạp.
- Báo cáo mức độ sạch theo thời gian (dashboard).

Không làm (ngoài phạm vi)

- Không xử lý dữ liệu đơn hàng, bảo hành, tồn kho linh kiện; chỉ dữ liệu khách hàng.
- Không tự động gộp hồ sơ khi chưa có xác nhận của nhân viên.
- Không xây dựng mô hình dự đoán khách hàng rời bỏ (luồng L9).
- Không gửi tin khuyến mãi / chiến dịch marketing thực tế.

1.3. Bảng thuật ngữ

Mỗi khái niệm chỉ dùng một tên trong SRS, sơ đồ Use Case và wireframe.

Thuật ngữ	Định nghĩa	Tên kỹ thuật
-----------	------------	--------------

Thuật ngữ	Định nghĩa	Tên kỹ thuật
Hồ sơ khách hàng	Một bản ghi mô tả một khách hàng (họ tên, số điện thoại, email, địa chỉ).	customer
Tập khách hàng thô	Tập CSV/Excel chứa hồ sơ khách hàng chưa làm sạch (nguồn mẫu: customers_raw.csv).	–
Đợt nạp	Một lần nạp một tập khách hàng thô vào hệ thống; có mã và thời điểm.	load_batch / batch_id
Bảng tạm	Nơi lưu dữ liệu thô sau khi nạp, trước khi làm sạch.	stg_customer
Hồ sơ đã làm sạch	Hồ sơ đã chuẩn hóa, số điện thoại hợp lệ và duy nhất.	customer_clean
Chuẩn hóa	Đưa số điện thoại về dạng 0xxxxxxxxx và họ tên về dạng thống nhất.	phone_norm, name_norm
Cặp nghi trùng	Hai hồ sơ khách hàng có khả năng là một người. Mỗi hồ sơ trong cặp gọi là hồ sơ nghi trùng.	dup_candidate
Điểm tương đồng	Số từ 0–100 đo mức giống nhau giữa hai hồ sơ trong cặp nghi trùng.	score
Hồ sơ gốc	Hồ sơ được giữ lại sau khi gộp; hồ sơ còn lại bị ngừng sử dụng.	survivor
Gộp	Hợp nhất hai hồ sơ thành một (có xác nhận của nhân viên).	MERGED
Giữ riêng	Quyết định coi hai hồ sơ là hai khách hàng khác nhau.	KEEP_SEPARATE
Quy tắc chất lượng dữ liệu	Một tiêu chí đánh giá bản ghi, có trọng số và ngưỡng.	dq_rule
Chỉ số mức độ sạch	Điểm 0–100 tổng hợp từ các quy tắc chất lượng dữ liệu cho một đợt nạp.	dq_result
Ngừng sử dụng	Xóa mềm: đánh dấu không dùng, giữ lịch sử (QT-13).	is_active = false

1.4. Tài liệu tham chiếu

- Case study Smart CRM – Mekong Mobile (Mục 2.3, 3, 5.2, 7-L7, 8, 9, 11).
- Bài thực hành 1 – Phiếu phạm vi đã duyệt (Buổi 2).

2. Mô tả tổng quan

2.1. Bối cảnh và vấn đề

Hiện có khoảng 65.000 hồ sơ khách hàng ghi nhận rời rạc. Một khách có thể tồn tại nhiều lần với nhiều số điện thoại (V1). Marketing (anh Khoa) không biết ai là khách tốt và gửi tin tràn lan (V5). Dữ liệu mẫu cố ý chứa lỗi: số điện thoại ba dạng (0901234567, 84901234567, 0901 234 567), ô trống, tên hoa/thường lẫn lộn, có dấu và không dấu, khoảng trắng thừa (Bảng 5.2).

2.2. Actor

Actor	Loại	Vai trò trong L7
Nhân viên Marketing	Người dùng chính	Nạp tập, chạy phát hiện, xem và xác nhận cặp nghi trùng, xem báo cáo, xuất danh sách hồ sơ lỗi.
Quản lý cửa hàng	Người dùng	Cấu hình quy tắc chất lượng dữ liệu, xem báo cáo mức độ sạch, xuất danh sách hồ sơ lỗi để cửa hàng sửa tại nguồn.
Tập nguồn Excel/CSV	Hệ thống ngoài (actor phụ)	Cung cấp dữ liệu khách hàng thô cho UC1.

2.3. Luồng nghiệp vụ tổng thể (bắt đầu → kết thúc)

1. Nhân viên Marketing nạp tập khách hàng thô → tạo một đợt nạp, ghi vào stg_customer.
2. Hệ thống chuẩn hóa số điện thoại và họ tên; gắn cờ hồ sơ thiếu hoặc sai định dạng.

- Hồ sơ có số điện thoại hợp lệ và chưa tồn tại được đưa vào `customer_clean`. Hồ sơ trùng số điện thoại với hồ sơ có sẵn không được tạo mới mà thành cặp nghi trùng (QT-01).
- Nhân viên Marketing chạy phát hiện: hệ thống so khớp mờ, tạo các cặp nghi trùng kèm điểm tương đồng.
- Nhân viên xem danh sách và quyết định từng cặp: Gộp hoặc Giữ riêng; hệ thống cập nhật `customer_clean` và ghi lịch sử.
- Hệ thống đánh giá đợt nạp theo `dq_rule`, lưu `dq_result`.
- Quản lý cửa hàng / Marketing xem báo cáo mức độ sạch theo thời gian. Kết thúc.

2.4. Ràng buộc và giả định

- Stack: Python (pandas, rapidfuzz), PostgreSQL, dashboard Streamlit hoặc Power BI / Looker Studio.
- Làm việc trên mẫu con 5.000–8.000 dòng của `customers_raw.csv` (~65.000 dòng, dữ liệu mô phỏng).
- Hệ thống dạng prototype chạy cục bộ; không tích hợp hệ thống thật của doanh nghiệp.
- Giả định: tệp nguồn có tối thiểu hai cột `full_name`, `phone`; các cột `email`, `address` có thể thiếu.
- Hồ sơ không có số điện thoại hợp lệ không vào `customer_clean` mà ở lại `stg_customer` kèm cờ lỗi, và được liệt kê trong báo cáo hồ sơ lỗi (UC9).

2.5. Thực thể dữ liệu (chi tiết ở `data-requirement-spec.md`)

`load_batch`, `stg_customer`, `customer_clean`, `dup_candidate`, `dq_rule`, `dq_result`.

3. Yêu cầu chức năng

3.1. Danh sách User Story

Vai trò, mục tiêu, giá trị nổi trực tiếp về vấn đề V1/V5 ở Bảng 2.2 của case study.

ID	User Story	MoSCoW
US1	Là Nhân viên Marketing, tôi muốn nạp tệp khách hàng thô (CSV/Excel) vào hệ thống và nhận số điện thoại đã ở dạng chuẩn 0xxxxxxxx để không phải sửa tay từng dòng dữ liệu rải rác (V1).	MUST
US2	Là Nhân viên Marketing, tôi muốn họ tên khách được chuẩn hóa về một dạng thống nhất để so khớp mờ cho kết quả chính xác hơn và danh sách gọi tên khách đúng, đẹp.	SHOULD
US3	Là Nhân viên Marketing, tôi muốn hệ thống tự phát hiện các cặp hồ sơ nghi trùng và cho điểm tương đồng để không phải dò thủ công 18–22% hồ sơ trùng (V1).	MUST
US4	Là Nhân viên Marketing, tôi muốn xem danh sách cặp nghi trùng sắp theo điểm tương đồng giảm dần để xử lý các cặp có khả năng trùng cao nhất trước.	SHOULD
US5	Là Nhân viên Marketing, tôi muốn xác nhận từng cặp nghi trùng là gộp hoặc giữ riêng để hồ sơ khách hàng được hợp nhất đúng mà không bị gộp nhầm hai người khác nhau.	MUST
US6	Là Quản lý cửa hàng, tôi muốn cấu hình trọng số và ngưỡng của các quy tắc chất lượng dữ liệu để tiêu chí đánh giá phù hợp từng giai đoạn mà không cần sửa mã.	SHOULD

ID	User Story	MoSCoW
US7	Là Quản lý cửa hàng, tôi muốn chỉ số mức độ sạch được tính và lưu cho từng đợt nạp để biết một đợt dữ liệu đạt hay chưa đạt chất lượng.	SHOULD
US8	Là Quản lý cửa hàng, tôi muốn xem báo cáo mức độ sạch dữ liệu theo thời gian để biết chất lượng dữ liệu đang cải thiện hay xấu đi, thay vì chờ tổng hợp thủ công (V4).	SHOULD
US9	Là Quản lý cửa hàng, tôi muốn xuất danh sách hồ sơ thiếu hoặc sai định dạng ra tệp CSV để cửa hàng sửa tại nguồn và lỗi không lặp lại ở đợt sau.	COULD
US10	Là Nhân viên Marketing, tôi muốn hệ thống tự động gộp các cặp có điểm tương đồng rất cao mà không cần xác nhận để tiết kiệm thời gian xử lý.	WON'T (loại khỏi phạm vi: gộp nhầm khách khó hoàn tác, xem QL7-01)
US11	Là Quản lý cửa hàng, tôi muốn số điện thoại khách bị che với nhân viên thông thường để giảm rủi ro lộ dữ liệu cá nhân (QT-15).	SHOULD

3.1.1. Kiểm tra INVEST và lỗi thường gặp

ID	I	N	V	E	S	T	Ghi chú xử lý
US1	✓	✓	✓	✓	✓	✓	Chuẩn hóa số điện thoại là kết quả bắt buộc của bước nạp (QT-02) nên nằm trong cùng story; chuẩn hóa họ tên tách riêng ở US2.
US2	✓	✓	✓	✓	✓	✓	Sửa lỗi “mơ hồ”: quy tắc tên được định nghĩa cụ thể ở FR-03.
US3	✓	✓	✓	✓	✓	✓	Công thức điểm và ngưỡng nêu ở FR-04, kiểm chứng được bằng tập cập gán nhãn tay.
US4	✓	✓	✓	✓	✓	✓	Phụ thuộc dữ liệu từ US3, kiểm thử được bằng dữ liệu cập mẫu.
US5	✓	✓	✓	✓	✓	✓	“Gộp hoặc giữ riêng” là hai nhánh của một quyết định, không phải hai yêu cầu.
US6	✓	✓	✓	✓	✓	✓	–
US7	✓	✓	✓	✓	✓	✓	–
US8	✓	✓	✓	✓	✓	✓	Mức chi tiết: theo đợt nạp, ngày, quy tắc.
US9	✓	✓	✓	✓	✓	✓	–
US10	✓	–	✓	–	✓	✓	Nêu giải pháp thay vì vấn đề, và mâu thuẫn với phạm vi đã duyệt; giữ lại để ghi nhận quyết định WON'T.
US11	✓	✓	✓	✓	✓	✓	–

3.1.2. Tiêu chí chấp nhận (Given – When – Then) cho story MUST

US1 – Nạp tệp khách hàng thô và chuẩn hóa số điện thoại

- AC1.1 (luồng chính): Given một tệp CSV hợp lệ có cột full_name và phone, 5.000 dòng; When nhân viên chọn tệp và bấm nạp; Then hệ thống tạo một đợt nạp mới và ghi đủ 5.000 dòng vào stg_customer kèm batch_id, báo số dòng đã nạp.
- AC1.2 (chuẩn hóa): Given các số điện thoại dạng +84901234567, 84901234567, 0901 234 567, 0901.234.567; When đợt nạp được xử lý; Then phone_norm của cả bốn dòng đều là 0901234567; dòng không quy về được 10 chữ số bắt đầu bằng 0 được gán cờ INVALID_PHONE.
- AC1.3 (ngoại lệ): Given tệp thiếu cột bắt buộc phone hoặc sai định dạng tệp; When nhân viên bấm nạp; Then hệ thống từ chối cả đợt, thông báo rõ tên cột thiếu, và stg_customer không thay đổi.

US3 – Phát hiện cặp nghi trùng


- AC3.1: Given hai hồ sơ có phone_norm giống nhau; When nhân viên chạy phát hiện; Then hệ thống tạo một cặp nghi trùng loại EXACT_PHONE với trạng thái PENDING và điểm tương đồng.
- AC3.2: Given hai hồ sơ có số điện thoại khác nhau đúng một chữ số và họ tên giống nhau sau khi bỏ dấu; When chạy phát hiện; Then cặp được tạo với điểm tương đồng ≥ 85 (ngưỡng mặc định).
- AC3.3 (ngoại lệ): Given một hồ sơ không có số điện thoại; When chạy phát hiện; Then hệ thống không đưa hồ sơ đó vào so khớp, gán cờ MISSING_PHONE, và không tạo cặp chỉ dựa trên tên giống nhau.

US5 – Xác nhận gộp hoặc giữ riêng

- AC5.1 (gộp): Given một cặp PENDING; When nhân viên chọn “Gộp”, chọn hồ sơ gốc và xác nhận; Then customer_clean còn một hồ sơ hiệu lực (trường trống được bổ sung từ hồ sơ còn lại), hồ sơ còn lại is_active = false, cặp chuyển MERGED, lịch sử ghi người thực hiện và thời điểm.
- AC5.2 (giữ riêng): Given một cặp PENDING có hai số điện thoại khác nhau; When nhân viên chọn “Giữ riêng”; Then cặp chuyển KEEP_SEPARATE, hai hồ sơ không đổi, cặp không được đề xuất lại ở các lần phát hiện sau.
- AC5.3 (ngoại lệ): Given một cặp PENDING và nhân viên chưa quyết định; When đột phát hiện kết thúc hoặc điểm tương đồng là 100; Then hệ thống không tự động gộp, cặp giữ nguyên PENDING (QL7-01).

3.2. Use Case Diagram

File gốc: docs/usecase_L7.drawio (mở bằng draw.io).



Hình 3.1 – Use Case Diagram luồng L7: Chất lượng dữ liệu khách hàng

Ranh giới hệ thống: Hệ thống Smart CRM – Mekong Mobile · L7 Chất lượng dữ liệu khách hàng.
Actor đều nằm ngoài ranh giới.

UC	Tên use case	Actor	Quan hệ
UC1	Nạp dữ liệu khách hàng thô	Nhân viên Marketing; Tập nguồn Excel/CSV	«include» UC2, «include» UC7
UC2	Chuẩn hóa số điện thoại và họ tên	(do UC1 gọi)	—
UC3	Phát hiện hồ sơ nghi trùng	Nhân viên Marketing	—
UC4	Xem danh sách cặp nghi trùng	Nhân viên Marketing	—
UC5	Xác nhận gộp hoặc giữ riêng cặp nghi trùng	Nhân viên Marketing	«include» UC4
UC6	Cấu hình quy tắc chất lượng dữ liệu	Quản lý cửa hàng	—
UC7	Tính chỉ số mức độ sạch dữ liệu	(do UC1 gọi)	—
UC8	Xem báo cáo mức độ sạch theo thời gian	Nhân viên Marketing; Quản lý cửa hàng	—
UC9	Xuất danh sách hồ sơ lỗi	Nhân viên Marketing; Quản lý cửa hàng	—

3.3. Đặc tả chi tiết UC5 – Xác nhận gộp hoặc giữ riêng cặp nghi trùng

(Chọn UC5 vì đây là use case quan trọng nhất: bước duy nhất làm thay đổi hồ sơ đã làm sạch và là điểm kiểm soát “không tự động gộp”).

Mục	Nội dung
Mã / Tên	UC5 – Xác nhận gộp hoặc giữ riêng cặp nghi trùng

Mục	Nội dung
Actor chính	Nhân viên Marketing
Mục tiêu	Quyết định một cặp nghi trùng là cùng một khách hàng (gộp) hoặc khác nhau (giữ riêng) và cập nhật hồ sơ đã làm sạch.
Điều kiện trước	Đã đăng nhập; UC3 đã chạy; có ít nhất một cặp ở trạng thái PENDING.
Điều kiện sau (thành công)	Cặp ở trạng thái MERGED hoặc KEEP_SEPARATE; customer_clean cập nhật đúng; lịch sử ghi người, thời điểm, điểm tương đồng. Không có hồ sơ nào bị xóa vật lý (QT-13).
Điều kiện sau (thất bại)	Dữ liệu không đổi, cặp vẫn PENDING.
Quy tắc liên quan	QT-01, QT-13, QT-15, QL7-01

Luồng chính (gộp) 1. Nhân viên mở danh sách cặp nghi trùng (UC4) và chọn một cặp. 2. Hệ thống hiển thị hai hồ sơ cạnh nhau (tên, số điện thoại che theo QT-15, email, địa chỉ), điểm tương đồng và các trường khác nhau. 3. Nhân viên chọn quyết định Gộp. 4. Hệ thống yêu cầu chọn hồ sơ gốc. 5. Nhân viên chọn hồ sơ gốc. 6. Hệ thống hiển thị bản xem trước hồ sơ sau gộp (giữ giá trị của hồ sơ gốc, bổ sung trường trống từ hồ sơ còn lại). 7. Nhân viên bấm Xác nhận. 8. Hệ thống kiểm tra số điện thoại sau gộp vẫn duy nhất trong customer_clean (QT-01). 9. Hệ thống cập nhật hồ sơ gốc, đặt hồ sơ còn lại is_active = false và merged_into = <hồ sơ gốc> (QT-13), chuyển cặp sang MERGED, ghi lịch sử, kích hoạt tính lại chỉ số mức độ sạch (UC7). 10. Hệ thống thông báo thành công và quay lại danh sách. Kết thúc.

Luồng ngoại lệ (đánh số theo bước)

- 3a. Nhân viên chọn “Giữ riêng”: hệ thống chuyển cặp sang KEEP_SEPARATE, ghi lý do (nếu có) và loại cặp khỏi danh sách PENDING; use case kết thúc thành công. Riêng cặp EXACT_PHONE: hai hồ sơ cùng số điện thoại không thể cùng tồn tại trong customer_clean (QT-01), nên hệ thống yêu cầu nhập số điện thoại hợp lệ khác cho một hồ sơ; nếu không có, hệ thống từ chối “Giữ riêng” và quay lại bước 3.
- 3b. Nhân viên chọn “Để sau”: cặp giữ PENDING, quay lại danh sách.
- 5a. Hai hồ sơ có số điện thoại khác nhau: hệ thống yêu cầu chọn số điện thoại chính cho hồ sơ gộp; số còn lại được lưu vào lịch sử gộp (không mất thông tin). Tiếp tục bước 6.
- 6a. Cặp đã được xử lý bởi người khác trong lúc xem: hệ thống báo “Cặp này đã được xử lý”, làm mới danh sách, quay lại bước 1.
- 8a. Số điện thoại sau gộp trùng với một hồ sơ thứ ba trong customer_clean: hệ thống từ chối gộp, hiển thị hồ sơ thứ ba và gợi ý xử lý cặp liên quan trước; quay lại bước 1.
- 9a. Lỗi ghi cơ sở dữ liệu: hệ thống hoàn tác toàn bộ giao dịch (rollback), thông báo lỗi, cặp giữ PENDING, quay lại bước 1.

3.4. Danh sách yêu cầu chức năng (FR)

Mã	Yêu cầu chức năng	Ưu tiên
FR-01	Hệ thống cho phép nạp tệp CSV/Excel vào stg_customer, mỗi lần nạp tạo một batch_id; từ chối cả đợt nếu thiếu cột bắt buộc full_name, phone; cảnh báo khi nạp lại tệp đã nạp (cùng giá trị băm).	MUST
FR-02	Hệ thống chuẩn hóa số điện thoại về 10 chữ số bắt đầu bằng 0 (QT-02): bỏ dấu cách, dấu chấm, dấu gạch; đổi +84/84 đầu thành 0; gắn cờ INVALID_PHONE / MISSING_PHONE khi không hợp lệ.	MUST
FR-03	Hệ thống chuẩn hóa họ tên: bỏ khoảng trắng thừa, viết hoa chữ cái đầu mỗi từ; giữ nguyên dấu tiếng Việt; tạo thêm khóa tên không dấu dùng cho so khớp.	SHOULD

Mã	Yêu cầu chức năng	Ưu tiên
FR-04	Hệ thống phát hiện cặp nghi trùng bằng so khớp mờ; điểm tương đồng = $0,6 \times \text{độ giống số điện thoại} + 0,4 \times \text{độ giống họ tên}$ (không dấu); cặp có điểm $\geq$ ngưỡng (mặc định 85) hoặc cùng số điện thoại chuẩn hóa được ghi vào dup_candidate trạng thái PENDING.	MUST
FR-05	Hệ thống hiển thị danh sách cặp nghi trùng sắp theo điểm giảm dần, lọc theo trạng thái và khoảng điểm, xem hai hồ sơ cạnh nhau.	SHOULD
FR-06	Hệ thống cho phép xác nhận Gộp hoặc Giữ riêng từng cặp; gộp cập nhật customer_clean, ngừng sử dụng hồ sơ còn lại, ghi lịch sử; không bao giờ tự động gộp.	MUST
FR-07	Hệ thống cho phép thêm/sửa/tắt quy tắc dq_rule (loại kiểm tra, trọng số, ngưỡng đạt); tổng trọng số các quy tắc đang bật phải bằng 1,0.	SHOULD
FR-08	Hệ thống tính tỉ lệ đạt từng quy tắc và chỉ số mức độ sạch của từng đợt nạp, lưu vào dq_result; tính lại khi có gộp.	SHOULD
FR-09	Hệ thống hiển thị báo cáo mức độ sạch theo thời gian: xu hướng theo đợt nạp, theo ngày; phân rã theo quy tắc; số cặp nghi trùng theo trạng thái.	SHOULD
FR-10	Hệ thống xuất danh sách hồ sơ có cờ lỗi (MISSING_PHONE, INVALID_PHONE, thiếu họ tên) của một đợt nạp ra tệp CSV.	COULD
FR-11	Hệ thống che số điện thoại (ví dụ 090****567) với mọi vai trò trừ Quản lý và Ban giám đốc (QT-15).	SHOULD

4. Yêu cầu phi chức năng (có ngưỡng đo được)

Mã	Nhóm	Yêu cầu	Cách kiểm chứng
NFR-01	Hiệu năng	Nạp và chuẩn hóa tệp 8.000 dòng trong ≤ 60 giây; chạy phát hiện cặp nghi trùng trên 8.000 hồ sơ trong ≤ 120 giây (dùng kỹ thuật blocking, không so sánh toàn bộ cặp).	Đo thời gian chạy trên máy phát triển, 3 lần, lấy lớn nhất.
NFR-02	Độ chính xác chuẩn hóa	Số điện thoại hợp lệ được chuẩn hóa đúng $\geq 99\%$ trên tập kiểm thử 200 dòng gán nhãn tay, bao gồm cả bốn dạng lỗi ở Bảng 5.2.	Test tự động so với nhãn tay.
NFR-03	Chất lượng phát hiện trùng	Trên tập 300 cặp gán nhãn tay: precision $\geq 85\%$ và recall $\geq 80\%$ ở ngưỡng điểm mặc định 85.	Tính precision/recall; chỉnh ngưỡng nếu chưa đạt.
NFR-04	Toàn vẹn dữ liệu	100% số điện thoại trong customer_clean đúng mẫu $^{0\d{9}}\$$ và duy nhất (QT-01, QT-02); 0 hồ sơ bị xóa vật lý (QT-13).	Truy vấn kiểm tra sau mỗi đợt nạp.
NFR-05	Tái lập	Nạp lại cùng tệp và cùng cấu hình cho kết quả giống nhau 100% (số cặp nghi trùng, chỉ số mức độ sạch); mọi bước ngẫu nhiên đặt seed và ghi vào README.	So sánh kết quả hai lần chạy.
NFR-06	Hiệu năng báo cáo	Dashboard tải xong ≤ 5 giây với ≤ 24 đợt nạp.	Đo thời gian tải.
NFR-07	Bảo mật	0 thông tin bí mật (mật khẩu, khóa) trong repo; thông tin kết nối chỉ trong .env (không commit); số điện thoại hiển thị dạng che với vai trò không phải Quản lý/Ban giám đốc (QT-15).	Quét repo; kiểm tra giao diện theo vai trò.
NFR-08	Truy vết	100% thao tác gộp/giữ riêng có bản ghi lịch sử gồm người thực hiện, thời điểm, điểm tương đồng.	Đối chiếu dup_candidate với thao tác.

5. Quy tắc nghiệp vụ

Quy tắc của case study áp dụng cho L7

Mã	Quy tắc	Áp dụng ở
----	---------	-----------

Mã	Quy tắc	Áp dụng ở
QT-01	Số điện thoại khách hàng duy nhất. Khi số đã tồn tại, hiển thị hồ sơ có sẵn thay vì tạo hồ sơ mới.	FR-02, FR-04, FR-06, UC5 (8a)
QT-02	Số điện thoại chuẩn hóa về 10 chữ số bắt đầu bằng 0; các dạng +84..., 84..., dấu cách, dấu chấm đều quy về dạng chuẩn.	FR-02, US1
QT-13	Không xóa vật lý hồ sơ khách hàng; chỉ ngừng sử dụng, giữ lịch sử.	FR-06, NFR-04
QT-14	Nhân viên chỉ xem dữ liệu đơn vị mình; quản lý xem toàn bộ đơn vị phụ trách.	Phạm vi xem báo cáo (FR-09)
QT-15	Số điện thoại hiển thị dạng che với mọi vai trò trừ Quản lý và Ban giám đốc.	FR-11, UC5

Quy tắc riêng của luồng L7

Mã	Quy tắc
QL7-01	Không tự động gộp hồ sơ trong bất kỳ trường hợp nào (kể cả điểm = 100); mọi lần gộp cần xác nhận của nhân viên.
QL7-02	Cập nhật trùng khi điểm tương đồng $\geq$ ngưỡng (mặc định 85, cấu hình được) hoặc cùng số điện thoại chuẩn hóa.
QL7-03	Điểm tương đồng = $0,6 \times \text{độ giống số điện thoại} + 0,4 \times \text{độ giống họ tên}$. Độ giống số điện thoại = 100 nếu bằng nhau, ngược lại là tỉ lệ giống chuỗi 10 chữ số. Độ giống họ tên tính trên tên không dấu, không phân biệt hoa/thường, không phụ thuộc thứ tự từ.
QL7-04	Hồ sơ không có số điện thoại hợp lệ chỉ ở lại stg_customer kèm cờ lỗi, không vào customer_clean, không tham gia so khớp.
QL7-05	Cặp đã KEEP_SEPARATE không được đề xuất lại.
QL7-06	Chỉ số mức độ sạch của đợt = $\Sigma (\text{trọng số quy tắc} \times \text{tỉ lệ bản ghi đạt quy tắc}) \times 100$; tổng trọng số các quy tắc đang bật bằng 1,0. Phân loại: ≥ 90 Tốt; 75 đến dưới 90 Chấp nhận được; dưới 75 Kém.
QL7-07	Khi gộp hai hồ sơ có số điện thoại khác nhau, bắt buộc chọn số chính; số còn lại lưu vào lịch sử gộp.

6. Bảng truy vết

FR	User Story	Use Case	MoSCoW
FR-01	US1	UC1	MUST
FR-02	US1	UC1, UC2	MUST
FR-03	US2	UC2	SHOULD
FR-04	US3	UC3	MUST
FR-05	US4	UC4	SHOULD
FR-06	US5	UC5	MUST
FR-06 (ràng buộc, nêu ở QL7-01)	US10	UC5	WON'T
FR-07	US6	UC6	SHOULD
FR-08	US7	UC7	SHOULD
FR-09	US8	UC8	SHOULD
FR-10	US9	UC9	COULD
FR-11	US11	UC4, UC5	SHOULD

Kiểm tra truy vết ngược: UC1–UC9 đều xuất hiện ít nhất một lần ở cột Use Case; US1–US11 đều xuất hiện ở cột User Story.

Phụ lục A. Data Requirement Specification – L7

Sinh viên: Dương Diễm My – 2374802010318 · Track DA · Đính kèm BT1 (xem docs/srs.md).

Lưu ý đo trên dữ liệu thật: các ô __ % ở mục 2 phải được điền sau khi chạy script profiling ở Phụ lục A trên mẫu customers_raw.csv thật. Danh sách cột nguồn là giả định theo case study (Mục 5.2, 8); đối chiếu với header thật của tệp rồi sửa nếu khác.

1. Bảng nguồn dữ liệu

Hệ thống nguồn	Tệp / định dạng	Tần suất cập nhật	Khối lượng ước tính	Ghi chú
Hồ sơ khách hàng thô hợp nhất từ Excel từng cửa hàng, Zalo, sổ tay bảo hành (V1)	customers_raw.csv (UTF-8)	Nạp theo đợt, theo yêu cầu (đề xuất hằng tháng)	~65.000 dòng; mẫu con 5.000–8.000 dòng để xử lý	Dữ liệu mô phỏng, cố ý có lỗi; không commit tệp lớn (data/raw/ nằm trong .gitignore), chỉ commit mẫu vài trăm dòng ở data/sample/
Tệp Excel khách hàng của cửa hàng (nếu bổ sung)	.xlsx	Theo đợt	Vài trăm đến vài nghìn dòng/tệp	Cùng cấu trúc cột sau khi ánh xạ

2. Từ điển dữ liệu nguồn (customers_raw.csv, giả định)

Cột	Kiểu	Ý nghĩa	Giá trị hợp lệ	Tỉ lệ thiếu (đo trên mẫu)
full_name	Văn bản	Họ tên khách	2–120 ký tự, không chứa chữ số	__ %
phone	Văn bản	Số điện thoại, nhiều dạng: 0901234567, 84901234567, 0901 234 567, +84...	Sau chuẩn hóa: ^0\d{9}\$	__ %
email	Văn bản	Thư điện tử	Đúng mẫu email; có thể trống	__ %
address	Văn bản	Địa chỉ liên hệ	≤ 255 ký tự; có thể trống	__ %
source (nếu có)	Văn bản	Nguồn ghi nhận (cửa hàng / Zalo / sổ bảo hành)	Một trong các nguồn đã biết	__ %
created_at (nếu có)	Văn bản	Thời điểm ghi nhận	Ngày hợp lệ; có thể lần 3 định dạng	__ %

Lỗi quan sát được cần phát hiện (theo Bảng 5.2): số điện thoại ba dạng và ô trống; tên hoa/thường lẫn lộn, có dấu và không dấu, khoảng trắng thừa; hồ sơ trùng (ước tính 18–22%).

3. Mô hình dữ liệu của luồng (6 bảng)

Bốn bảng đã đăng ký ở Buổi 2 (stg_customer, customer_clean, dq_rule, dq_result) cộng hai bảng bổ sung cần cho chức năng xác nhận gộp và theo dõi đợt nạp (load_batch, dup_candidate). Mô hình chi tiết (ERD) hoàn thiện ở Buổi 5.

Bảng	Cột chính	Ghi chú
load_batch	batch_id PK, file_name, file_hash, row_count, loaded_at, loaded_by	Mỗi lần nạp một dòng; file_hash để cảnh báo nạp lại.
stg_customer	stg_id PK, batch_id FK, row_no, full_name_raw, phone_raw, email_raw, address_raw, phone_norm, name_norm, name_key, flags, status	Giữ nguyên giá trị thô để đối chiếu; flags chứa INVALID_PHONE, MISSING_PHONE, MISSING_NAME...
customer_clean	customer_id PK, full_name, phone UNIQUE NOT NULL, email, address, is_active, merged_into, created_at, updated_at	Bám theo bảng customer tham chiếu (Mục 8); thêm is_active, merged_into cho xóa mềm (QT-13).

Bảng	Cột chính	Ghi chú
dup_candidate	pair_id PK, record_a, record_b, match_type (EXACT_PHONE/FUZZY), phone_sim, name_sim, score, status (PENDING/MERGED/KEEP_SEPARATE), survivor_id, decided_by, decided_at, note, batch_id	Lưu lịch sử quyết định (NFR-08).
dq_rule	rule_id PK, rule_code, rule_name, rule_type, field_name, weight, pass_threshold, is_active	Cấu hình được (FR-07).
dq_result	result_id PK, batch_id FK, rule_id FK (NULL = dòng tổng), total_records, pass_count, pass_rate, weighted_score, measured_at	Chỉ số mức độ sạch của đợt = dòng tổng.

4. Quy tắc chất lượng dữ liệu phải đạt (có ngưỡng)

Mã quy tắc	Loại	Mô tả	Trọng số	Ngưỡng đạt
DQ-01	Completeness	phone không trống	0,25	$\geq 98\%$
DQ-02	Validity	phone_norm khớp $^0\d{9}\$$	0,25	$\geq 95\%$
DQ-03	Completeness	full_name không trống	0,15	$\geq 99\%$
DQ-04	Validity	full_name 2–120 ký tự, không chứa chữ số	0,10	$\geq 97\%$
DQ-05	Uniqueness	Không trùng theo khóa nghiệp vụ phone_norm	0,20	$\geq 98\%$ (tức tỉ lệ trùng $\leq 2\%$)
DQ-06	Validity	email đúng mẫu khi có giá trị	0,05	$\geq 95\%$
		Tổng trọng số	1,00	

Công thức: chỉ số mức độ sạch của một đợt = $\Sigma (\text{trọng số} \times \text{tỉ lệ đạt quy tắc}) \times 100$. Mục tiêu chung: completeness tổng thể $\geq 95\%$; không trùng theo khóa nghiệp vụ; chỉ số mức độ sạch sau làm sạch ≥ 90 (loại Tốt) và cao hơn chỉ số trước làm sạch ít nhất 10 điểm.

Ví dụ tính (số liệu minh họa, không phải kết quả đo): tỉ lệ đạt DQ-01..06 lần lượt $0,92 \cdot 0,85 \cdot 0,98 \cdot 0,95 \cdot 0,80 \cdot 0,90 \rightarrow 100 \times (0,25 \times 0,92 + 0,25 \times 0,85 + 0,15 \times 0,98 + 0,10 \times 0,95 + 0,20 \times 0,80 + 0,05 \times 0,90) = 100 \times 0,8195 \approx 81,95 \rightarrow$ loại Chấp nhận được.

5. Thuật toán so khớp mờ (đặc tả)

- Chuẩn bị: phone_norm (QT-02); name_key = họ tên bỏ dấu, chữ thường, bỏ khoảng trắng thừa.
- Blocking (tránh so sánh mọi cặp, NFR-01): chỉ so sánh hai hồ sơ nếu cùng 5 số đầu, hoặc cùng 5 số cuối của số điện thoại, hoặc cùng từ cuối của name_key (tên gọi).
- Độ giống số điện thoại: 100 nếu bằng nhau; ngược lại `rapidfuzz.fuzz.ratio` trên hai chuỗi 10 chữ số.
- Độ giống họ tên: `rapidfuzz.fuzz.token_sort_ratio` trên name_key.
- Điểm tương đồng = $0,6 \times \text{độ giống số điện thoại} + 0,4 \times \text{độ giống họ tên}$.
- Quyết định: cùng phone_norm $\rightarrow$ cặp EXACT_PHONE; ngược lại điểm $\geq 85 \rightarrow$ cặp FUZZY. Ví dụ: hai số khác đúng 1 chữ số (độ giống 90) và tên giống hệt $\rightarrow 0,6 \times 90 + 0,4 \times 100 = 94 \rightarrow$ được đề xuất.
- Ngưỡng 85 là giá trị khởi đầu, chỉnh theo kết quả precision/recall (NFR-03).

6. Câu hỏi phân tích và mức chi tiết báo cáo

#	Câu hỏi phân tích	Truy vết User Story	Mức chi tiết
Q1	Mỗi đợt nạp có bao nhiêu % hồ sơ trùng, thiếu, sai định dạng?	US7, US8	Theo đợt nạp
Q2	Chỉ số mức độ sạch thay đổi thế nào theo thời gian?	US8	Theo đợt nạp, theo ngày, theo tháng
Q3	Quy tắc nào kéo chỉ số xuống nhiều nhất?	US7, US8	Theo quy tắc (DQ-01..06)
Q4	Có bao nhiêu cặp nghi trùng đã gộp, giữ riêng, còn chờ xử lý?	US5, US8	Theo đợt nạp, theo trạng thái
Q5	Phân bố điểm tương đồng và tỉ lệ gộp theo khoảng điểm là bao nhiêu (để chỉnh ngưỡng)?	US3, US5	Khoảng điểm 85–89, 90–94, 95–100
Q6	Dạng lỗi số điện thoại nào phổ biến nhất (84..., dấu cách, thiếu số)?	US1, US9	Theo loại lỗi

7. Phụ lục – Script profiling tỉ lệ thiếu (chạy để điền mục 2)

```
import pandas as pd

df = pd.read_csv("data/raw/customers_raw.csv", dtype=str).sample(n=6000,
random_state=42)
missing = (df.isna() | (df.apply(lambda s: s.str.strip() ==
""))).mean().mul(100).round(2)
print(missing) # điền vào cột "Tỉ Lệ thiếu"
print(df.columns.tolist()) # đối chiếu với từ điển dữ liệu ở mục 2
```

Ghi random_state=42 (seed) vào README để tái lập.